PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ
BIG DATA – BSI/BES
PROF. JOELTON DEONEI GOTZ

MapReduce – Versão Português

Você foi contratado para integrar a equipe de análise de dados de uma grande empresa multinacional. Nessa equipe, é utilizada a tecnologia Hadoop para processar grandes bases de dados utilizando a linguagem de programação Java. No projeto atual, você deverá utilizar o modelo de programação MapReduce para extrair uma série de informações sobre transações comerciais internacionais realizadas pela empresa nos últimos 30 anos. Essas transações estão armazenadas em um dataset estruturado com 10 colunas, conforme a descrição apresentada na tabela abaixo:

Variable (column)	Description
Country	Country involved in the commercial transaction
Year	Year in which the transaction took place
Commodity code	Commodity identifier
Commodity	Commodity description
Flow	Flow, e.g. Export or Import
Price	Price, in USD
Weight	Commodity weight
Unit	Unit in which the commodity is measured, e.g. Number of items
Amount	Commodity amount given in the aforementioned unit
Category	Commodity category, e.g. *Live animals*

O dataset contêm mais 8 milhões de exemplos (ou seja, 8 milhões de linhas que representam as transações comerciais da empresa). Esse dataset é disponibilizado no formato CSV em que as colunas são separadas por ponto e vírgula ";". Na imagem abaixo, são apresentadas as primeiras 5 linhas do arquivo, cada uma com um total de 10 colunas.

```
Afghanistan;2016;010410;Sheep, live;Export;6088;2339;Number of items;51;01_live_animals
Afghanistan;2016;010420;Goats, live;Export;3958;984;Number of items;53;01_live_animals
Afghanistan;2008;010210;Bovine animals, live pure-bred breeding;Import;1026804;272;Number of items;3769;01_live_animals
Albania;2016;010290;Bovine animals, live, except pure-bred breeding;Import;2414533;1114023;Number of items;6853;01_live_animals
Albania;2016;010392;Swine, live except pure-bred breeding > 50 kg;Import;14265937;9484953;Number of items;96040;01_live_animals
```

De acordo com o contexto apresentado acima, você e sua equipe são responsáveis por desenvolver soluções em MapReduce capazes de responder as seguintes perguntas:

1. **(0,2 ponto)** Número de transações envolvendo o Brasil.
2. **(0,2 ponto)** Número de transações por ano.
3. **(0,2 ponto)** Número de transações por categoria.
4. **(0,2 ponto)** Número de transações por tipo de fluxo (flow).
5. **(0,3 ponto)** Valor médio das transações por ano somente no Brasil. **Necessário criar um writable customizado**.
6. **(0,3 ponto)** Transação mais cara e mais barata no Brasil em 2016. **Uso obrigatório do Combiner e criação de um writable customizado.**
7. **(0,3 ponto)** Valor médio das transações por ano, considerando somente as transações do tipo exportação (Export) realizadas no Brasil. **Uso obrigatório do Combiner e writable customizado.**
8. **(0,3 ponto**) Valor máximo das transações por ano no Brasil, realizando a ordenação de crescente, do maior valor médio para o menor. **Será necessário (obrigatório) utilizar a concatenação de Jobs.**
9. **(0,5 ponto)** Transação com o maior e menor preço (com base na coluna amount), por ano e país. **Obrigatório o uso de um Comparable writable e Combiner.**

Para cada um dos itens acima, forneça:

1. Será necessário retirar o cabeçalho.
2. Será necessário tratar dados faltantes.
3. Código fonte para a resolução do problema utilizando MapReduce em Java. **ATENÇÃO**: não serão consideradas como corretas, soluções que realizam a concatenação de strings para a formação de chaves ou valores compostos.
4. O resultado da execução em um arquivo separado e no formato txt.